



3차 프로젝트

$1 \pm 1 = 1$

손 엑스레이 분석을 통한 골 연령 및 키 성장 예측

최샘이 박지훈 주지윤 장유선 이현동

손 엑스레이 분석을 통한 골연령 및 키 성장 예측

contents

1



개요 및 주제선정

사용 데이터 설명,
주제 선정 배경과 주
제 관련 분석

2



이미지 전처리

OpenCV를 활용,
이미지 전처리과정

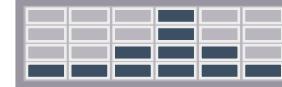
3



이미지 라벨링

TW3기법을 기반,
Roboflow와
Yolov5 모델로
관절 객체 탐지

4



골 연령 예측

골연령 예측에
최적화 된
TJ-Net 모델을
통한 골 연령 예측

5



키 성장 예측

성장 도표의
L,M,S값을 활용한
최종 신장 예측

6



기대효과 및 한계점

개요

데이터

X-ray 검사 이미지

골 연령 판독 검사의 기준

완손과 손목을 포함

2세부터 17세

남자 665명 / 여자 572명

검사 대상자의 기본 신체검사 기록

전문의 2명의 판독 결과 데이터

2017 소아청소년성장도표 (출처: 질병관리청)

제작환경 및 모듈



주제 선정



주제 선정 배경

“유아 및 청소년기에 소아비만, 성 조숙증과 같은 키 성장을 방해하는 질병의 발병률이 꾸준히 증가하는 추세”

의원급 표시과목별 성조숙증 치료 주사제 건강보험 청구 현황(사용량)

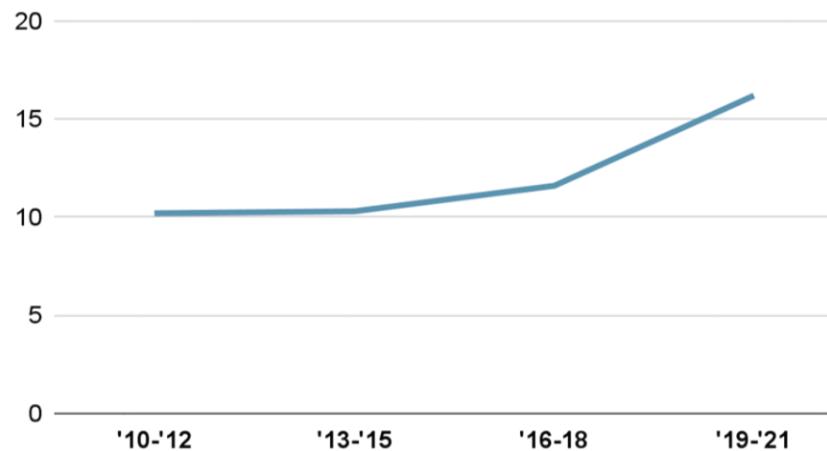
(단위 : 개, %)

구분	소아청소년과	일반	마취과	산부인과	이비인후과	내과	가정의학과	기타	계
2019년	23,282 (61.3)	12,574 (33.1)	1,149 (3.0)	208 (0.5)	596 (1.6)	119 (0.3)	31 (0.1)	1 (0.0)	37,960 (100.0)
2020년	45,579 (68.7)	17,328 (26.1)	2,578 (3.9)	515 (0.8)	0 (0.0)	174 (0.3)	48 (0.1)	129 (0.2)	66,351 (100.0)
2021년	67,323 (69.5)	24,371 (25.2)	2,995 (3.1)	994 (1.0)	815 (0.8)	260 (0.3)	105 (0.1)	4 (0.0)	96,866 (100.0)
19년 대비 증가율	189.2(▲) 93.8(▲) 160.7(▲) 377.9(▲) 36.7(▲) 118.5(▲) 238.7(▲) 300.0(▲) 155.2(▲)								

[자료] 국민건강보험공단-신현영 의원실 재구성
‘기타’ : 재활의학과 등 4과목

제공: 신현영 의원실

소아청소년 비만 유병률(2010-2021)



아이들의 키성장과 성장호르몬 치료에 관심증대 및 키 성장 클리닉에 대한 수요 증가

주제 분석

주제 선정

ISSUE

아이들의 키성장과
성장호르몬 치료에
관심증대 및
키 성장 클리닉에 대한
수요 증가

키 성장 요인

한가지 요인 만으로 결정되지는 않으며, 굉장히 많은 요소가 작용

성장단계 특징

유아기: 주로 영양에 의존

소아기: 주로 성장 호르몬에 의존하는 경향

사춘기: 성장호르몬과 성호르몬에 의해서 급격한 성장이 이루어짐

중요점

현재 이 소아가 키가 정상 코스 및 과정으로 크고 있는지 파악하는 것

키 성장 클리닉에서 치료의 시작은 현재 상태를 파악하고 키 성장 예측하는 것

골연령 측정?

키 성장 과정을 진단하고, 잔여 성장을 예측하며

호르몬 치료(성장호르몬)나 성장과 관련된 질환을 치료하는 데 도움을 줌

키 성장 예측시 전문적 지식과 많은 경험을 요구

따라서 효율적으로 골연령을 기반으로 성장 예측키를 분석하는 도구 필요



주제 분석

주제 선정

골 연령 예측을 통한 성 조숙증과 같은 유아의 성장관련 질환을 판별			
BONE DETECTION	소아의 성장	비 정상적 성장 속도	참고: 정상적인 성장속도 기준
<p>골 연령</p> <p>X-ray 검사 상의 보이는 나이를 뜻하며 골 성숙도를 나타내는 개념</p>	<p>유전, 호르몬, 영양적 요인 뿐만 아니라 질환이나 정신사회적 요인들에 의해서도 영향</p> <p>비정상적인 수준의 성장 변화가 발견 → 질환의 신호</p>	<p>빠름 → 성 조숙증의 가능성 (성호르몬의 분비를 촉진시켜 2차 성장을 앞당기는 결과)</p> <p>느림 → 저 신장의 원인 파악 중요 (유전성, 성장호르몬 결핍증, 체질성 성장지연, 터너 증후군 등)</p>	<p>출생 시 (10개월) 50cm</p> <p>출생 후 ~ 1세 25cm</p> <p>1세 ~ 2세 12 ~ 13cm</p> <p>2세 ~ 사춘기 전 5~6 cm</p> <p>사춘기 ~ 14, 15세 7~12cm (연 기준)</p>

프로젝트 진행

7

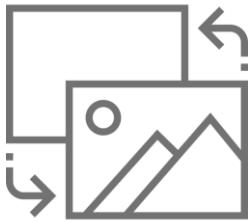
프로젝트 진행 순서



데이터

Input

완손 엑스레이
표본 데이터



이미지 전처리

빼 도출



이미지 라벨링

라벨 기준

TW3 기법

샘플라벨링

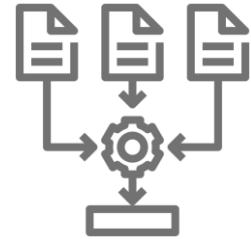
roboflow

객체탐지

YOLOv5

라벨값

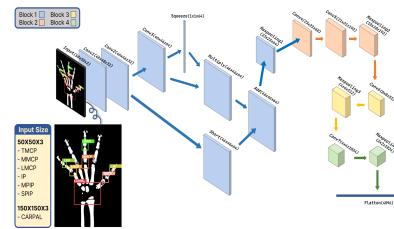
관절 객체 좌표



골연령 예측

모델 구축

TJ-Net



키성장 예측

최종예측

성장도표 L/M/S

2

이미지 전처리

이미지 전처리 과정



OpenCV를 활용한 이미지 전처리



원본 이미지



최종 이미지

- 1 손 영역 추출
- 2 손목 Rotation
- 3 모폴로지 연산(뼈 영역 추출)
- 4 마스크 생성 및 뼈 도출

1 손 영역 추출

16

이미지 전처리

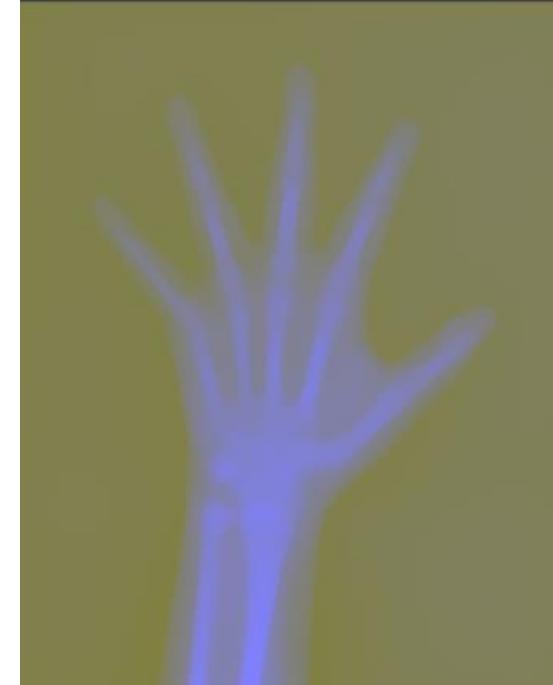


원본



밝기(선명도) 강조
: Lab이미지로 변환

* Lab 색상: 인간의 눈이 인지할 수 있는
색차를 거의 그대로 수치로 표현



잡음 제거
: Blur 처리

* medianBlur: 주변 픽셀들의 중앙값
(median)으로 픽셀 값을 대체

1 손 영역 추출

//

이미지 전처리



회색 조 변환

마스크생성

: 임계처리 및 외곽선 추출

- ① threshold 적용: 이미지의 평균값으로 이진화
- ② 이미지 중 가장 큰 외곽선 추출(손 영역)

배경 제거

: 비트연산을 통해 손영역만 추출

* bitwise_and

: 서로 공통으로 겹치는 부분 출력

2 손목 Rotation

이미지 전처리



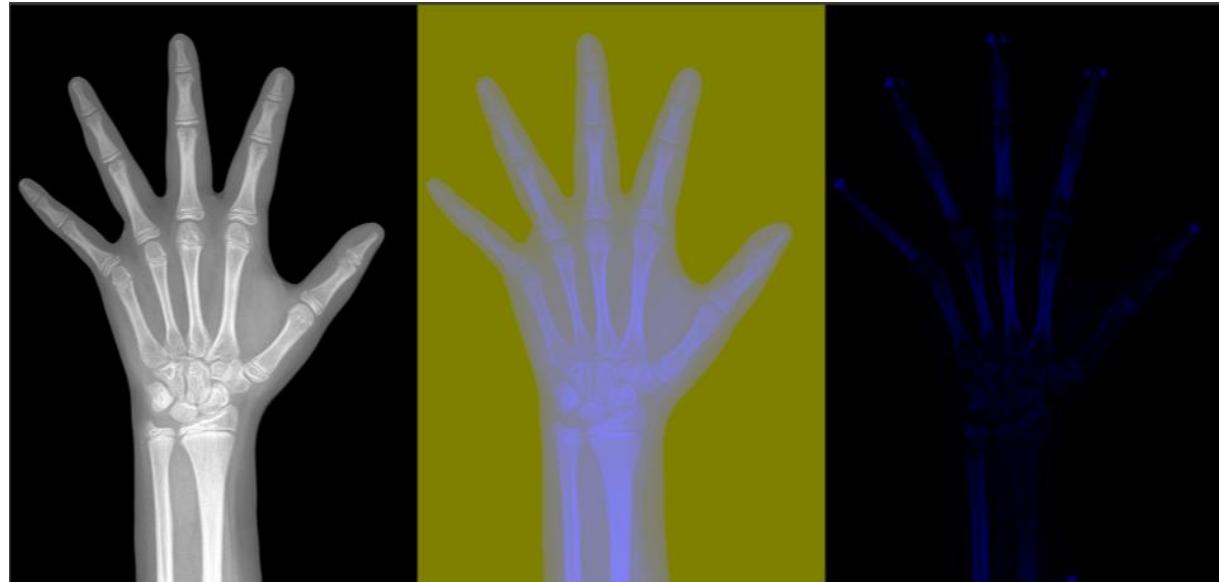
회전각도:
90 - atan2로
계산한 각도

모델의 정확도를 높이기 위해 이미지의 각도조정

- ① 손목의 시작과 중간 부분을 x, y로 설정
- ② 선형회귀(LinearRegression) 학습으로 x, y 그래프를 그림
- ③ 회귀 직선이 그림 밑 선을 기준으로 90° 가 되도록 회전

3 모폴로지 연산

이미지 전처리



원본

밝기 조정

모폴로지 연산

- ① Lab이미지 변환
- ② brightness함수작성
: 픽셀 밝기에 따른
가중치 추가

- ① 노이즈 제거
- ② 값이 큰 구간 강조
(밝은 구간 = 빠 부분)
- ③ TOPHAT 옵션 사용

모폴로지 연산이란?

팽창과 수축의 형태학적 변환을 결합하여 연산하는데 도움을 주는 함수



침식

어두운 부분의
노이즈를 제거하는
효과



팽창

밝은 부분의
노이즈를 제거하는
효과

→ 연산 시 형태가 변형되기도 하므로
두 방법을 결합하여 연산 할 수 있도록 도움

3 모폴로지 연산

이미지 전처리

모폴로지 연산 비교

각 모폴로지 연산 비교와 **TOPHAT**옵션 사용이유

비교 이미지



원본

opening 연산

close 연산

gradient 연산

tophat 연산

blackhat 연산



tophat 연산

원본 이미지와 opening 연산 결과의 차이

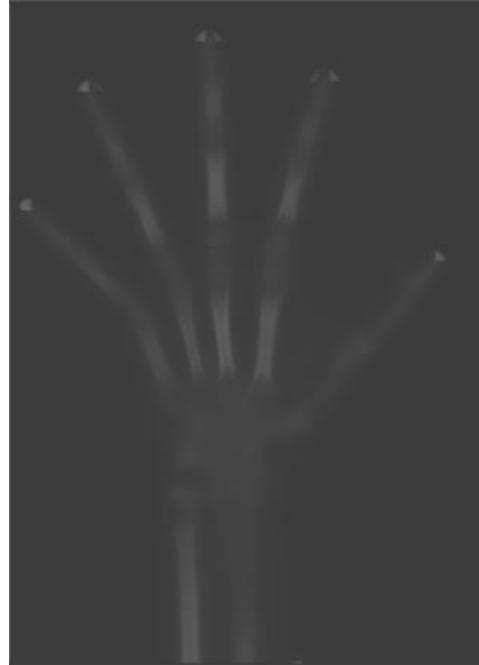
형태의 변형 없이 밝기가 크게 튀는 부분을 강조하여, 위의 예시 이미지에서 보이는 바와 같이 뼈 도출이 가장 잘되는 모습으로 확인

Opening 연산 : 침식 후 팽창 연산

- 주변보다 밝은 노이즈를 제거
- 독립 개체를 분리/ 돌출된 모양을 제거

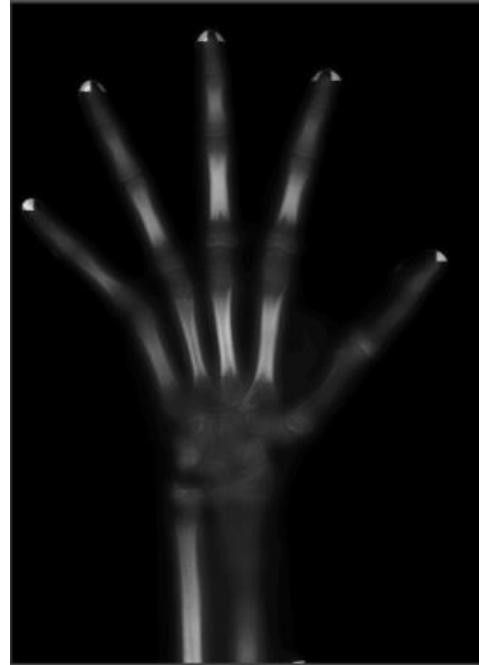
4 마스크 생성 및 뼈 도출

이미지 전처리



잡음감소와 회색조
: 블러처리를 통한 노이즈감소

* `bilateralFilter`: 에지가 아닌
부분에서만 blurring



정규화
: 대비조정



CLAHE
: 히스토그램 균등화

일정한 영역을 분리하여 해당
영역의 히스토그램 균등화 연산



마스크생성
: `findContours` 적용

- ① 이미지 이진화후 `findContours`
- ② 외곽선 라인으로 마스크 생성

CLAHE

(적응형 히스토그램 이퀄라이제이션)

좋은 이미지란?

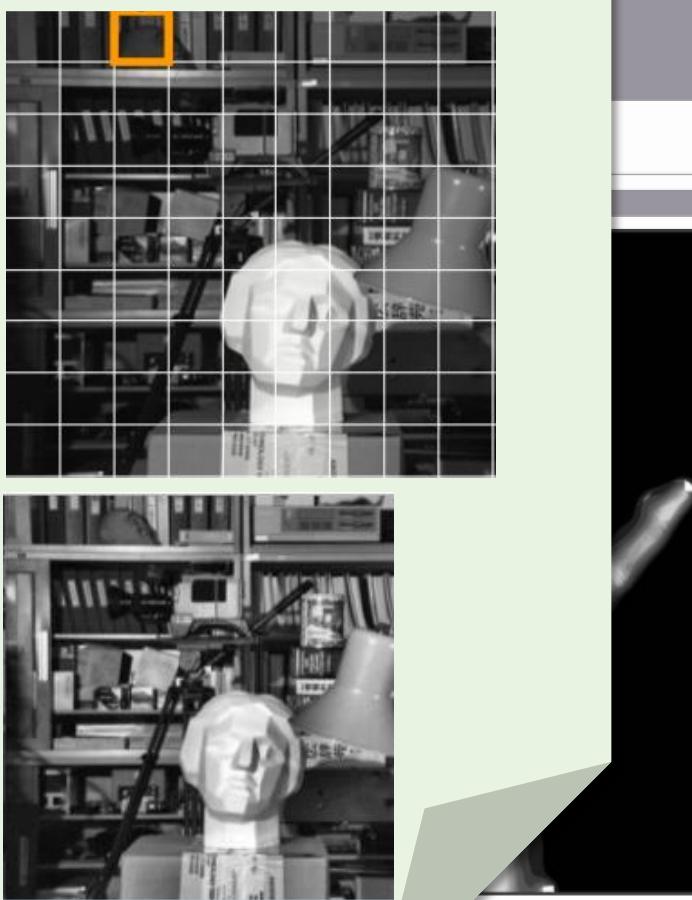
: 히스토그램이 전체영역에 골고루 분포

CLAHE 역할

- ① 이미지를 일정한 크기의 작은 블록으로 구분
- ② 블록별 히스토그램 균일화 실행
- ③ 이미지 전체에 대하여 균일화 달성

: 블러처리를 통한 노이즈감소

* bilateralFilter: 에지가 아닌
부분에서만 blurring



: 대비조정

CLAHE
: 히스토그램 균등화

일정한 영역을 분리하여 해당
영역의 히스토그램 균등화 연산

이미지 전처리

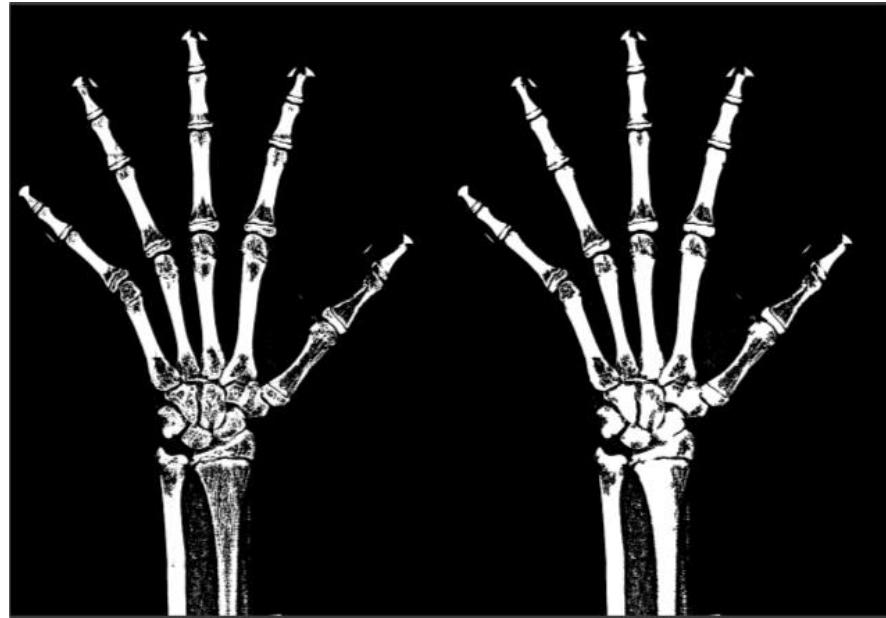


마스크생성
: findContours 적용

① 이미지 이진화후 findContours
② 외곽선 라인으로 마스크 생성

4 마스크 생성 및 뼈 도출 (최종이미지)

이미지 전처리



**밝은 부분 강조와
모폴로지 연산**

- 콘트라스트 조정으로
밝기 강조



외곽선 추출

- 뼈 형태 보정

**마스크 적용 하여
비트연산**

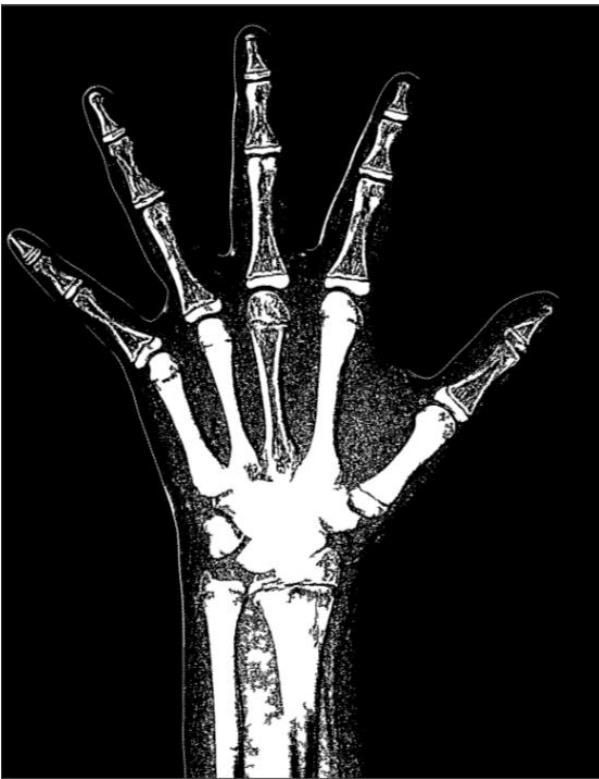
- 필요 없는 배경 완전제거
- 흑/백 분리



* 이미지 전처리 함수 값 조정 및 비교

이미지 전처리

이미지 전처리 함수 값 조정



(img, 10, 10, 10, 10)



(img, 60, 55, 50, 25)

`def Extraction(img, a, b, d, e)`

a 빠 강조를 위해 사용

: 모폴로지 함수에 적용하는 커널 크기

b 마스크생성을 위해 사용

: 모폴로지 함수에 적용하는 커널 크기

d e bilateralFilter(노이즈 제거)에 사용

- sigmaColor
- sigmaSpace

* sigmaColor

: 색 공간에서 필터의 표준 편차

* sigmaSpace

: 좌표 공간에서 필터의 표준 편차

3

이미지 라벨링

이미지 라벨링 과정



골 연령 측정 기법을 활용한 이미지 라벨링



Fig. 1 Separation Position of Hand Bone

1 골 연령 측정 방법

2 관절 Annotation

Roboflow를 활용하여 측정에 사용되는 관절 Annotate

3 관절 객체 탐지

전체 데이터에 YOLOv5 모델을 적용하여 관절 객체 탐지

4 검출 결과 및 잘못 탐지된 관절 객체 수정

1 골 연령 측정 방법

이미지 라벨링

GP 기법

(Greulich-Pyle and Bayley-Pinnea)

완손 30개 부위

표준 방사선 사진 중 검사자의 측정 사진과
유사한 사진 선택 후 골 연령 판정

- 방법이 단순, 짧은 평가시간 (약 1.4분)
- 검사 소요 시간이 짧아 임상에서 많이 사용

- 세밀한 골 연령 판독이 어려움
(표본 방사선 사진은 6개월~ 1년 간격 단위)
- 판독 오차로 인한 정확성 낮음

측정요소

측정방법

장점

단점

TW3 기법

(Tanner Whitehouse)

성별, 왼 손, 손목뼈 13개 부위

- 발달 정도를 단계별 점수 계산 후,
골 성숙 점수 산출
- 해당 점수를 골 연령 표를 통해 골 연령 측정

- 골 연령 표가 0.1년 단위로 구분되어 있어
정밀한 평가가 가능하며 정확성 높음
- 각 뼈의 성숙도를 점수화 평가하기 때문에
객관적인 평가가 가능

- GP 기법에 비하여 평가 과정이 복잡
- 수동 판단 작업으로 긴 평가시간
(7 ~ 10분 소요)

1 골 연령 측정 방법

이미지 라벨링

GP 기법

(Greulich-Pyle and Bayley-Pinnea)

완손 30개 부위

표준 방사선 사진 중 검사자의 측정 사진과
유사한 사진 선택 후 골 연령 판정

- 방법이 단순, 짧은 평가시간 (약 1.4분)
- 검사 소요 시간이 짧아 임상에서 많이 사용

- 세밀한 골 연령 판독이 어려움
(표본 방사선 사진은 6개월~ 1년 간격 단위)
- 판독 오차로 인한 정확성 낮음

측정요소

측정방법

장점

단점

TW3 기법

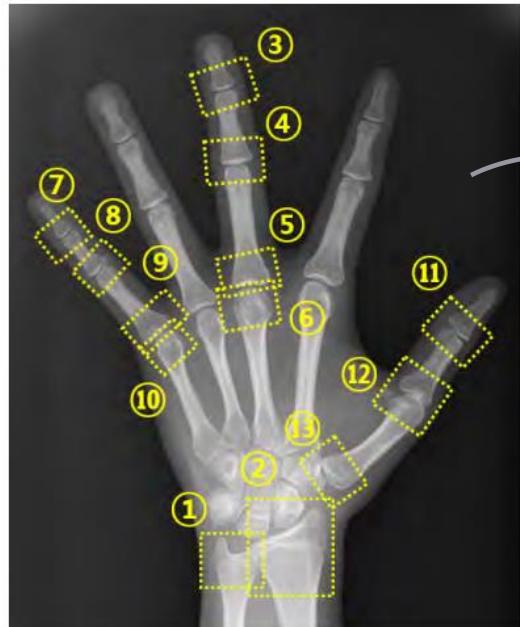
(Tanner Whitehouse)

성별, 완 손, 손목뼈 13개 부위

- ① 발달 정도를 단계별 점수 계산 후,
골 성숙 점수 산출
 - ② 해당 점수를 **골 연령 표**를 통해 골 연령 측정
- 골 연령 표가 **0.1년 단위**로 구분되어 있어 정밀한 평가가 가능하며 **정확성 높음**
 - 각 뼈의 성숙도를 **점수화 평가**하기 때문에 **객관적인 평가**가 가능
 - GP 기법에 비하여 평가 과정이 복잡
 - 수동 판단 작업으로 긴 평가시간
(7 ~ 10분 소요)

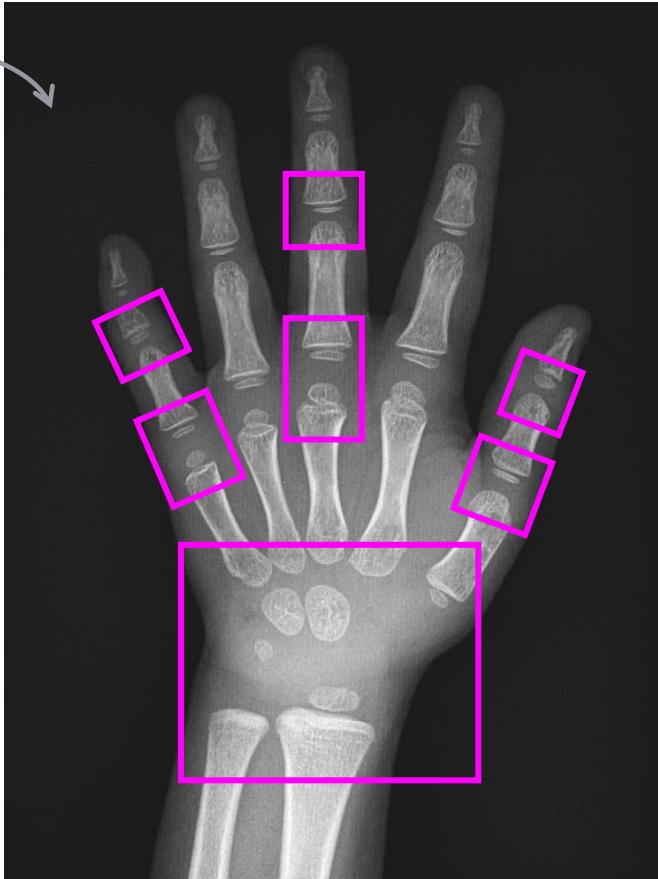
1 골 연령 측정 방법_TW3 기법

이미지 라벨링



TW3 기법

- ✓ 오른손에 비해 사용이 적어 손상이 적은 **왼손 엑스레이 사진 사용**
- ✓ **손목, 엄지, 중지, 소지의 13개의 뼈**를 기준으로 함



7개의 부위로 축소하여 객체 추출

효율성을 위하여 골 연령 예측에
꼭 필요한 부위를 선정

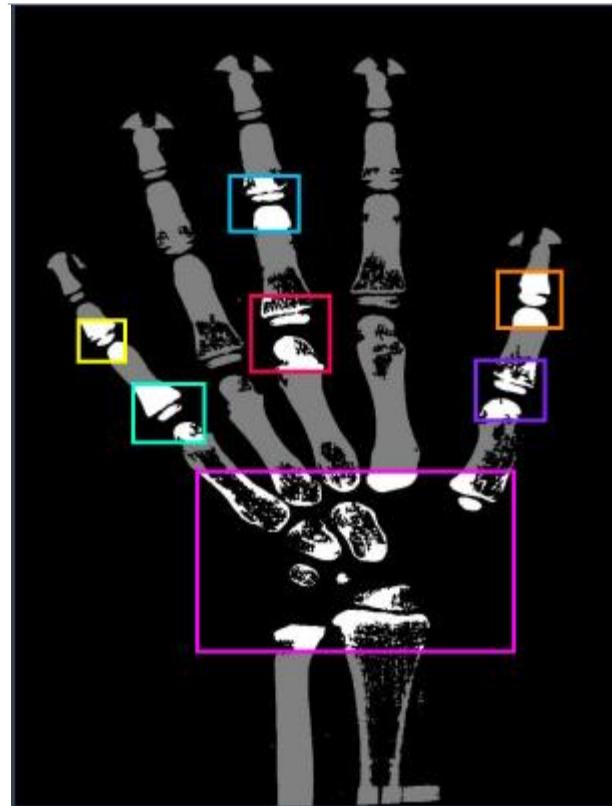


**성장판은 관절과
직접 연결되어 있는
길게 생긴 뼈 모양의
끝 부분에 위치**

손목부위	1+2+13번 함께 추출
엄지	11번 / 12번
중지	4번 / 5번+6번 함께 추출
소지	8번 / 9번+10번 함께 추출

2 관절 Annotation : Roboflow 활용

이미지 라벨링



데이터

객체박스

7개의 관절(TW3기반)

손목 0 / 엄지 1,4 /
중지 2,5 / 소지 3,6

● 0	1
● 1	1
● 2	1
● 3	1
● 4	1
● 5	1
● 6	1

총 1237개의 전처리 된 이미지

샘플 라벨링 데이터셋(Annotation)

train set

210개 이미지

원본 : 100장 / 자동 Augmentations : 110장

validation set

30개 이미지

test set

30개 이미지

3 관절 객체 탐지: YOLOv5 모델_기본 값 적용

이미지 라벨링

기본값 설정으로 학습한 결과

활성화 함수: SiLU / 옵티마이저: SGD

	mAP 50	mAP 50-95
YOLOx (x-large)	0.990	0.521
YOLOI (large)	0.989	0.510
YOLOm (medium)	0.991	0.512
YOLOs (small)	0.985	0.490

결과도출

YOLOx와 YOLOm의 성능지표 점수가 높음

YOLOx, YOLOm 모델을 수정하여 비교할 필요성이 있음

YOLO의 성능지표

mAP

(mean Average Precision)

① 개체 별 평균 정밀도(AP)를 계산

→ AP는 Precision과 Recall을 고려한 종합적 평가 지표이며 다양한 모델 비교에 용이

mAP계산:

모든 개체에 대한 평균 AP

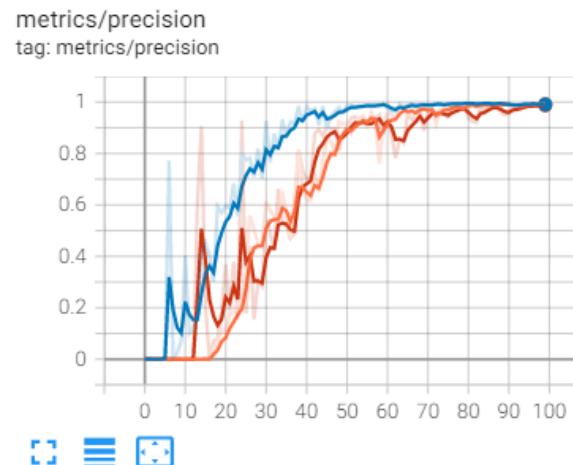
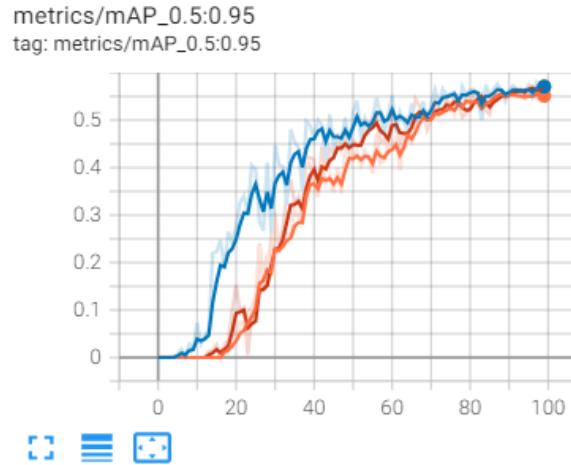
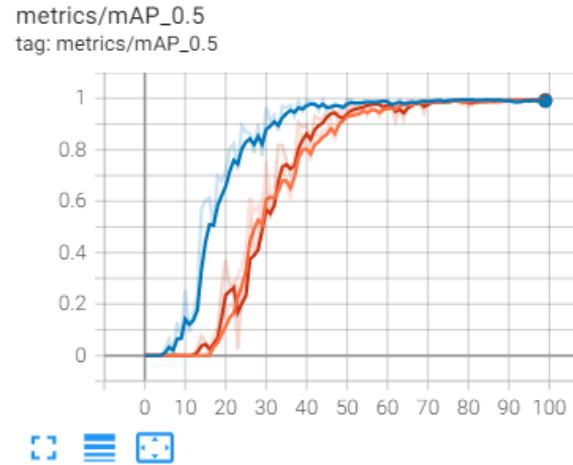
3 관절 객체 탐지: YOLOv5 모델 _Fine-Tuning

이미지 라벨링

		YOLOX				YOLOm			
변경할 활성화 함수	변경할 층	Conv / (Bottleneck: SiLU)		Conv / Bottleneck		Conv / (Bottleneck: SiLU)		Conv / Bottleneck	
		mAP 50	mAP 50-95						
ReLU		0.974	0.503	0.978	0.516	0.995	0.545	0.995	0.545
ELU		0.989	0.531	0.989	0.531	0.989	0.499	0.989	0.499
ReLU (Optimizer: Adam)		0.974	0.503	0.974	0.503	0.991	0.554	0.991	0.554
PReLU		0.99	0.533	0.992	0.517	0.995	0.528	0.995	0.528
LeakyReLU		0.980	0.516	0.980	0.516	0.989	0.525	0.989	0.525
GeLU		0.990	0.527	0.987	0.546	0.981	0.514	0.981	0.514
Hardswish		0.986	0.527	0.986	0.527	0.987	0.528	0.987	0.528
기본(SiLU) / (Optimizer: Adam)		0.960	0.481	0.960	0.481	0.991	0.554	0.991	0.554
기본(SiLU) / (Optimizer: AdamW)		0.988	0.560	0.998	0.560	0.992	0.555	0.992	0.555
변경할 활성화 함수		변경할 층				변경할 층			
		Conv / (Bottleneck: LeakyReLU)		Conv / (Bottleneck: LeakyReLU)		Conv / (Bottleneck: LeakyReLU)		Conv / (Bottleneck: LeakyReLU)	
		mAP 50		mAP 50-95		mAP 50		mAP 50-95	
Hardswish		0.986		0.527		0.987		0.528	

3 관절 객체 탐지: YOLOv5 모델 _ maP값 시각화

이미지 라벨링



최종 결과 그래프

가장 학습 결과가 좋게 나온
다음 3가지의 모델(설정 값 변경)의
결과 값 그래프 시각화

- train/yolov5m_ReLU
- train/yolov5m_PReLU
- train/yolov5x_SiLU_AdamW

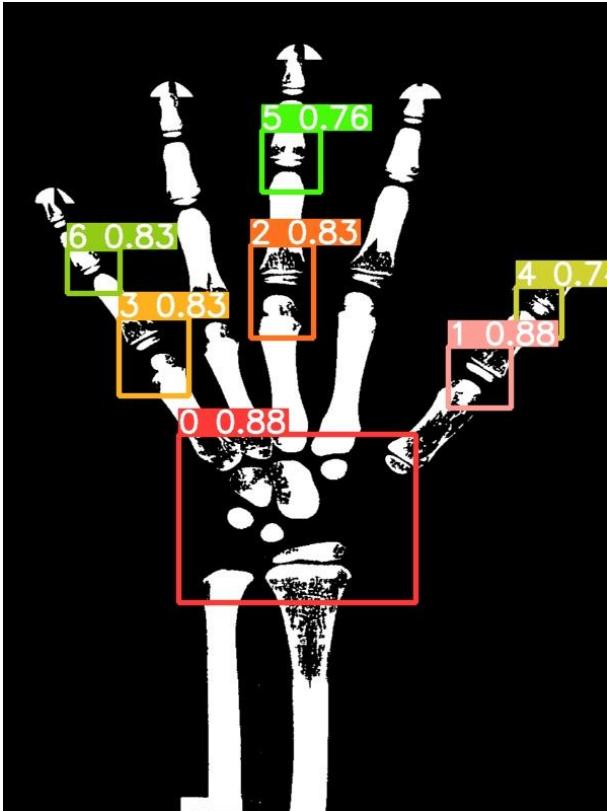
→ YOLOv5m(PReLU) 모델로
Image Detecting

4 검출 결과 및 잘못 탐지된 객체 수정

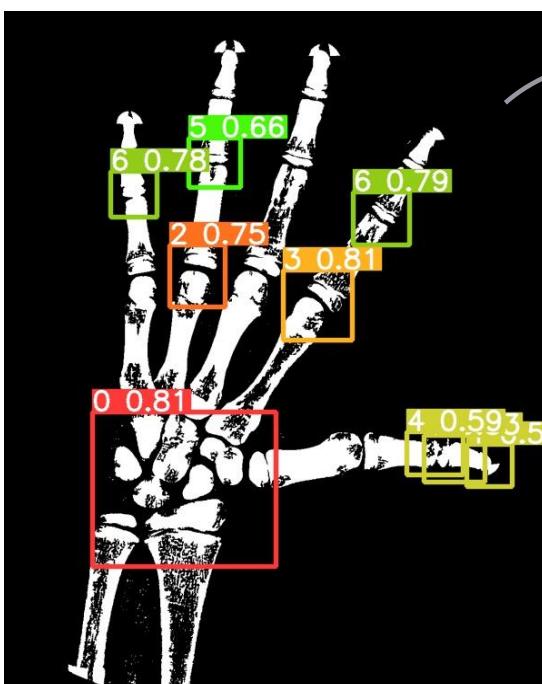
이미지 라벨링

YOLOv5m(PReLU) 모델로 검출한 결과

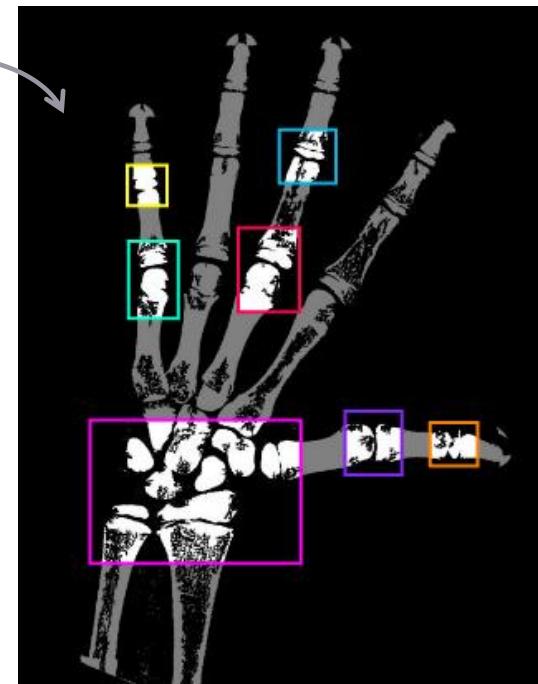
검출 성공: 1207개 이미지



검출 오류: 30개 이미지



Roboflow로 재 라벨링



검출오류 원인:

이미지 전 처리 과정에서 손목의 회전이 되지 않거나, 관절부위를 명확하게 구분해내지 못 한 경우 검출 오류 발생

4

골연령 예측

골 연령 예측 과정

TJ-Net모델로 골 연령 예측



성장판 닫힘



성장판 열림

- 1 데이터 준비
- 2 모델 구축 : TJ-Net
- 3 모델 학습 결과 비교
- 4 최적 모델의 결과

1 데이터 준비

골연령 예측

Data Information

No	각 성별에 따른 고유 번호
gender	성별
age	실제나이
BA_mean	전문가 2명이 판단한 골연령의 평균
img_path	전처리 완료된 이미지 경로

이미지 좌표(x,y,w,h)

CARPAL	0: 손목 관절
TMCP	1: 엄지 첫번째 관절
MMCP	2: 중지 첫번째 관절
LMCP	3: 소지 첫번째 관절
IP	4: 엄지 두번째 관절
MPIP	5: 중지 두번째 관절
LPIP	6: 소지 두번째 관절

관절 객체 탐지로 찾은 좌표의 Crop Image

CARPAL 114 478 395 738 LMCP 59 319 132 418



TMCP 427 375 496 451



MMCP 208 262 271 360



IP 492 302 545 362



MPIP 224 138 288 205



LPIP 59 229 108 287



[이미지 사이즈] 원본 : 224 x 224 / 손목 : 150 x 150 / 손가락 관절 : 50 x 50

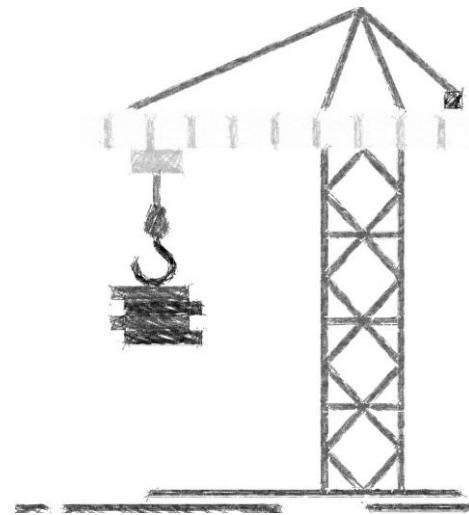
2 모델 구축: TJ-Net 모델

주제 선정

TW3 기법 적용 후 TJ-Net 모델 구축

중요도

가중치



TJ-Net은 이미지의 특징을 학습하면서, 이미지의 특정 영역에 더 많은 중요도를 부여하여 골연령을 추정

이를 위해 TJ-Net은 Self-attention mechanism을 사용

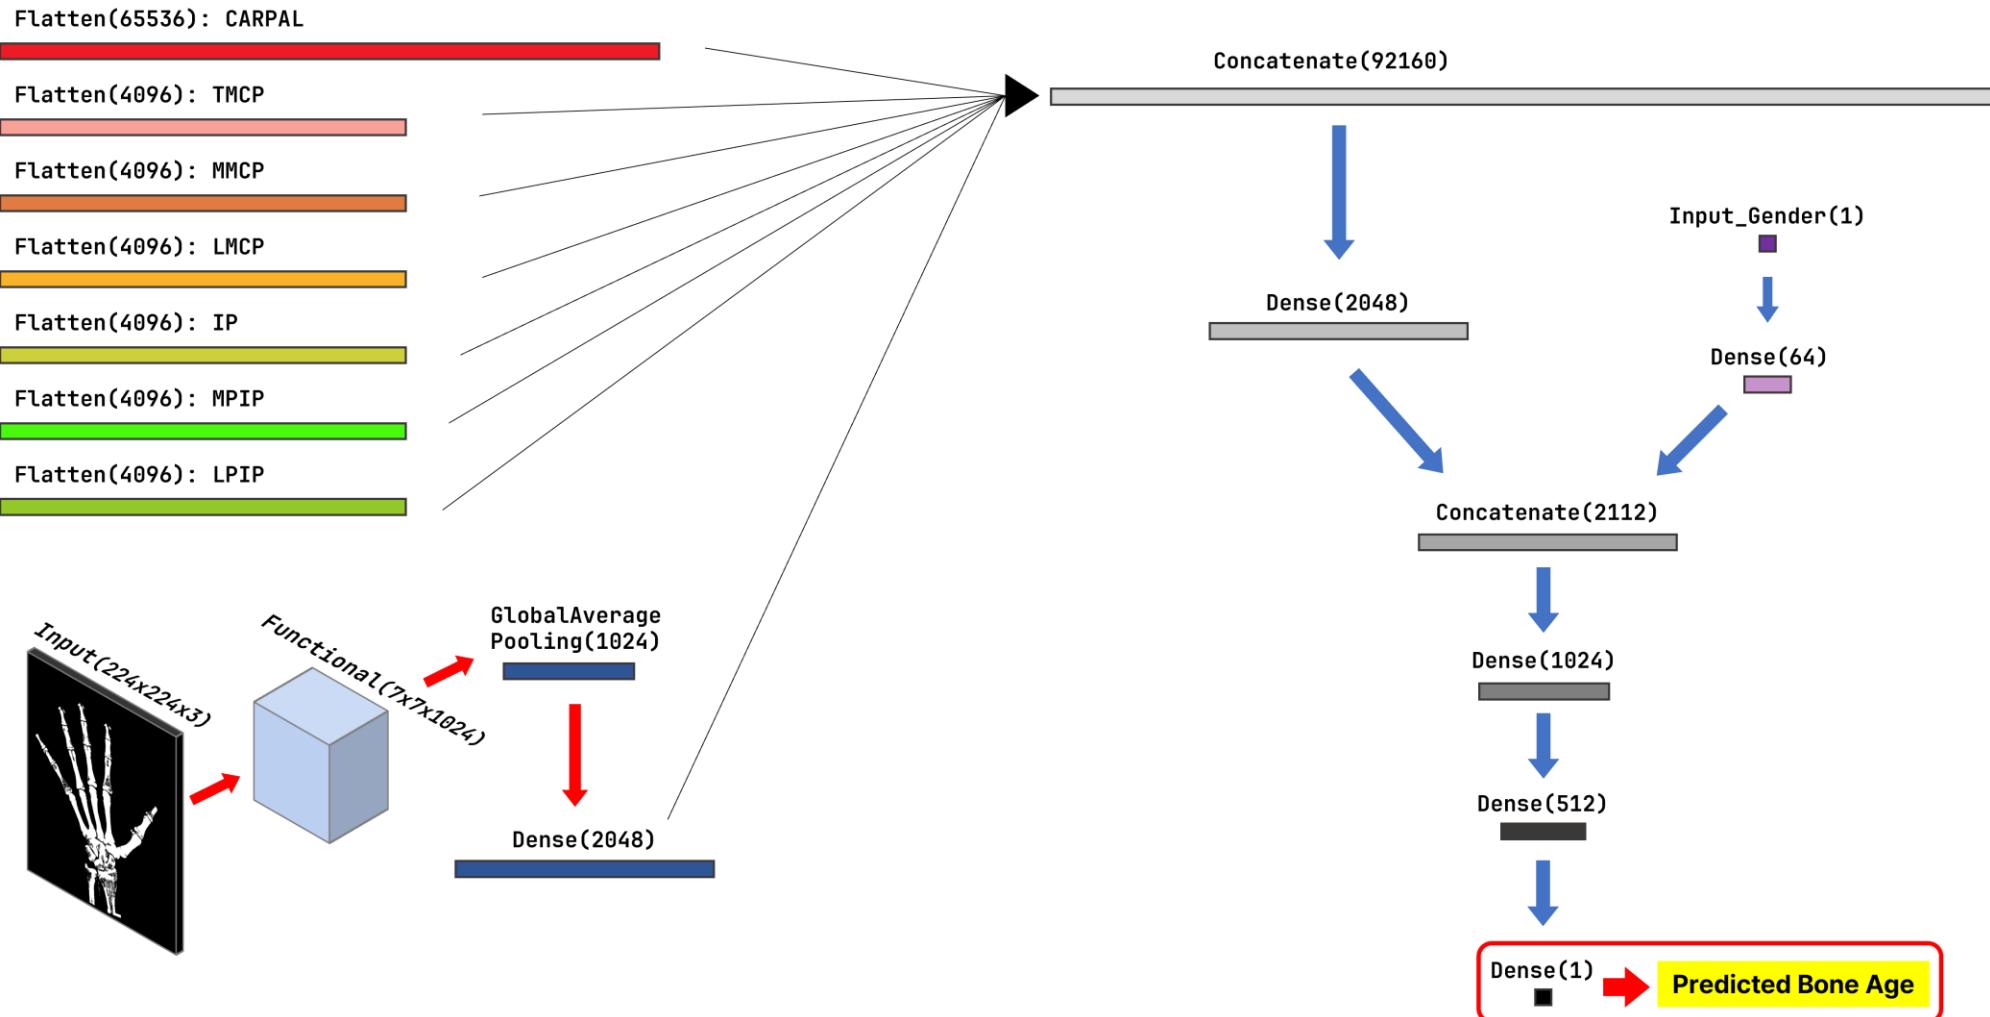
Self-attention mechanism:

입력 데이터의 다른 위치에 대한 상대적인 중요도를 계산,
특징 맵의 각 위치를 가중치로 조정
→ 특징 맵의 중요한 영역에 더 많은 관심

중요도, 가중치 → 가중치 설정 시 비교적 정확도와 일관성이 높은 TW3 기법

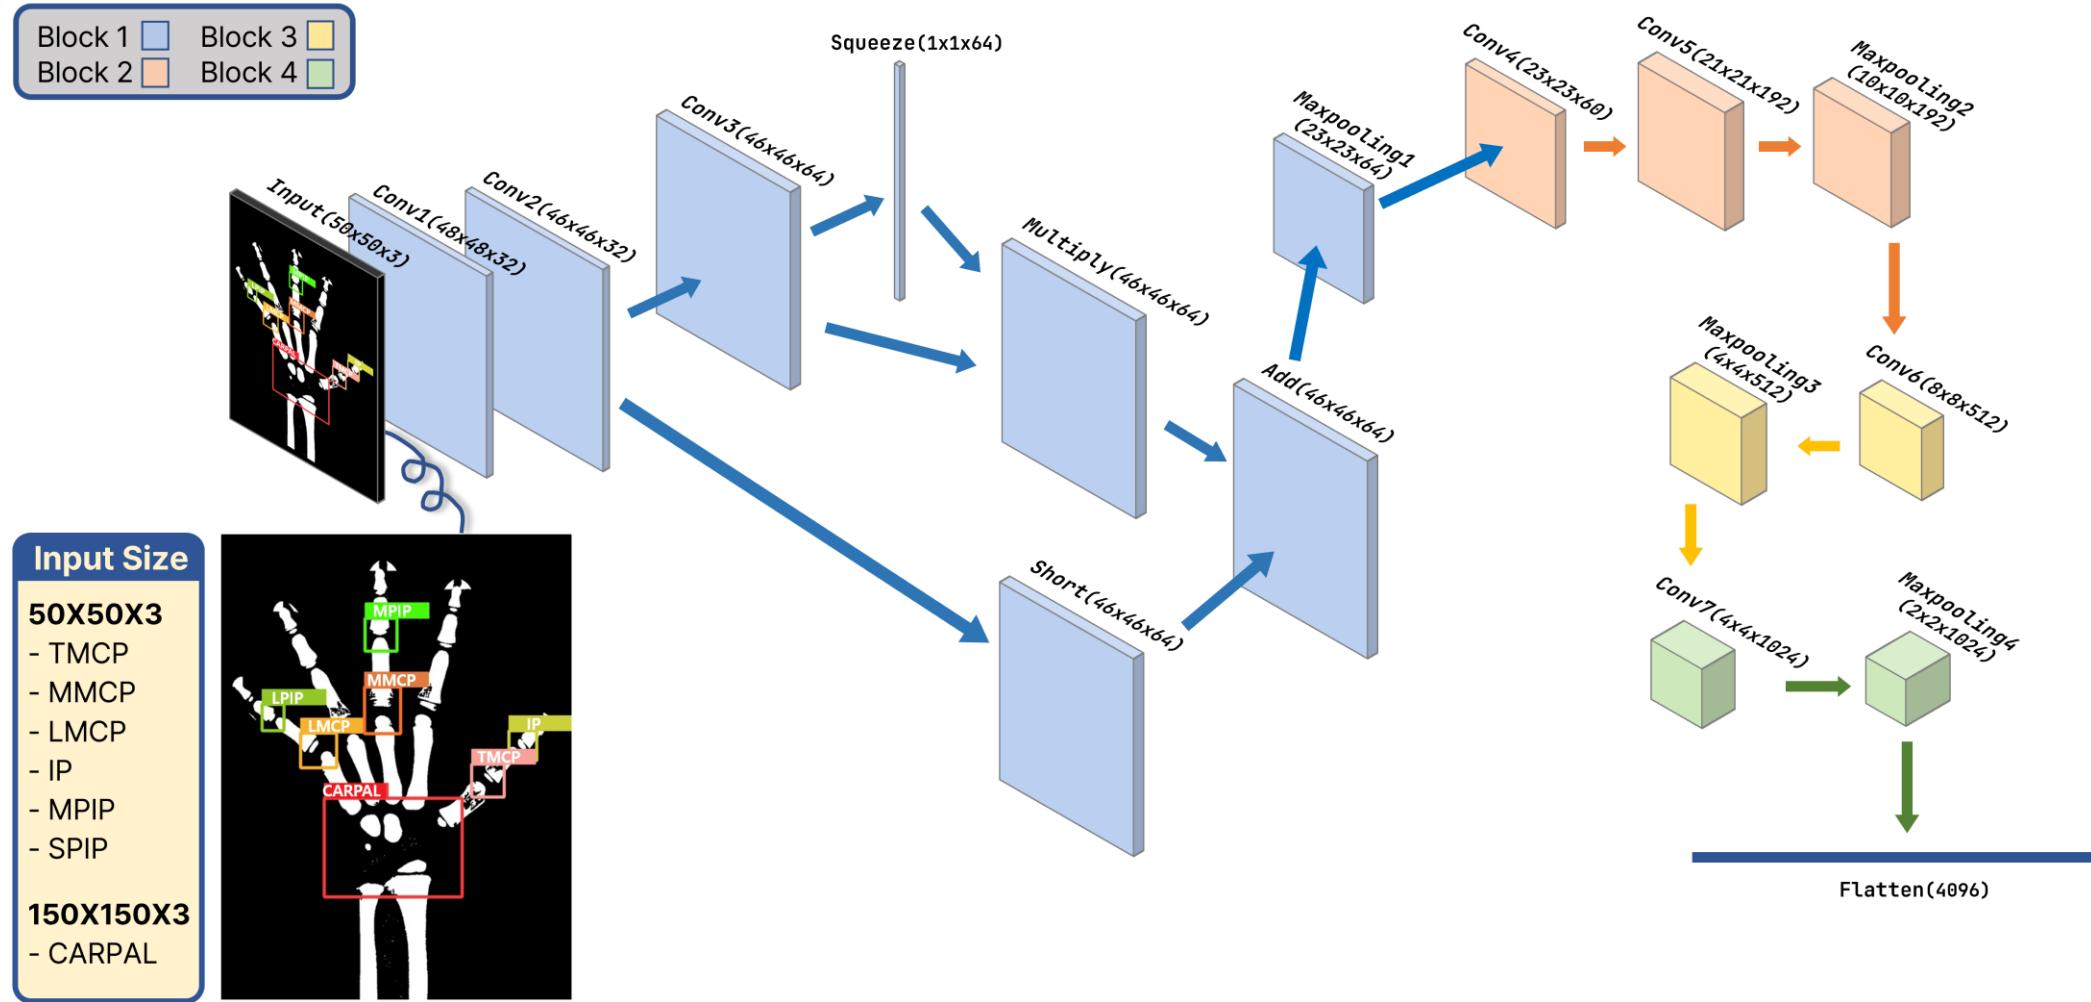
2 모델 구축: TJ-Net 모델 구조

골 연령 예측



2 모델 구축: TJ-Net 모델 구조

골 연령 예측



3 모델 학습 결과 비교

골연령 예측

Conv activation	Dense activation	Model optimizer	mse	mae
ReLU	relu	Nadam	0.372	0.471
	elu		0.324	0.438
	selu		0.337	0.453
	gelu		0.324	0.456
	tanh		0.328	0.470
	swish		0.269	0.403
	relu	SGD	0.814	0.755
		RMSProp	0.970	0.737
		Adam	0.524	0.575
		Adamax	0.414	0.575
		AdamW	0.517	0.559
PReLU	relu	Nadam	0.484	0.535
	elu		0.366	0.485
	selu		0.274	0.401
	gelu		0.293	0.435
	tanh		0.282	0.419
	swish		0.433	0.539

Conv activation	Dense activation	Model optimizer	mse	mae
ELU	relu	Nadam	0.670	0.638
	elu		0.403	0.488
	selu		0.892	0.738
	gelu		0.605	0.616
	tanh		0.642	0.607
	swish		0.443	0.527
	relu		0.436	0.517
	elu		0.386	0.499
	selu		0.341	0.457
	gelu		0.302	0.409
GELU	tanh		0.399	0.514
	swish		0.346	0.470

기본 값 : ReLU / relu / Nadam
Epochs : 50

모델 검증 지표

loss : mse

회귀 예측을 하기 때문에 손실 값으로 평가를 하게 되며,

MSE는 오차의 민감도를 높이기 때문에 회귀 예측 평가 시 중요한 평가 지표로 사용

metrics: mae

MAE는 10진수로 표기되므로 평가 결과를 확인 시, 직관적으로 오차 범위를 알 수 있어 보조적으로 평가에 사용

3 모델 학습 결과 비교

골연령 예측

표본 나이구분

유아기/소아기/청소년기

표본의 나이를 구분하여 학습한 결과 비교

구분 이유

- 청소년기의 자료가 비교적 적음
- **유아기엔 관절의 급격한 성장이 이루어지므로 학습 시 유리**

1

Conv activation: **ReLU**
Dense activation: **swish**
Model optimizer: **Nadam**

	MSE	MAE
유아기	0.0896	0.2098
소아기	0.0620	0.1728
청소년기	0.1204	0.2613

→ 소아기: 표본이 가장 많고, 비교적 적은 나이

2

Conv activation: **PRelu**
Dense activation: **selu**
Model optimizer: **Nadam**

	MSE	MAE
유아기	0.0826	0.1957
소아기	0.0966	0.2401
청소년기	0.1145	0.2624

최적 모델 ➔ Layer activation: **ReLU** / Dense activation: **swish** / Model optimizer: **Nadam**

4 최적 모델의 결과

골 연령 예측

최적 모델 학습 결과

Conv activation: **ReLU** / Dense activation: **swish** / Model optimizer: **Nadam**

No	gender	gen_code	height	bone_age
568	2	M	1	89.2
569	3	M	1	90.8
570	4	M	1	91.1
571	5	M	1	93.9
572	6	M	1	93.6
573	7	M	1	94.2
574	8	M	1	91.6
575	9	M	1	92.8
576	10	M	1	91.1
577	11	M	1	90.7

No	gender	gen_code	height	bone_age
0	1	F	2	88.9
1	2	F	2	95.9
2	3	F	2	88.2
3	4	F	2	88.7
4	5	F	2	90.8
5	6	F	2	91.5
6	7	F	2	90.5
7	8	F	2	92.4
8	9	F	2	91.3
9	10	F	2	92.0

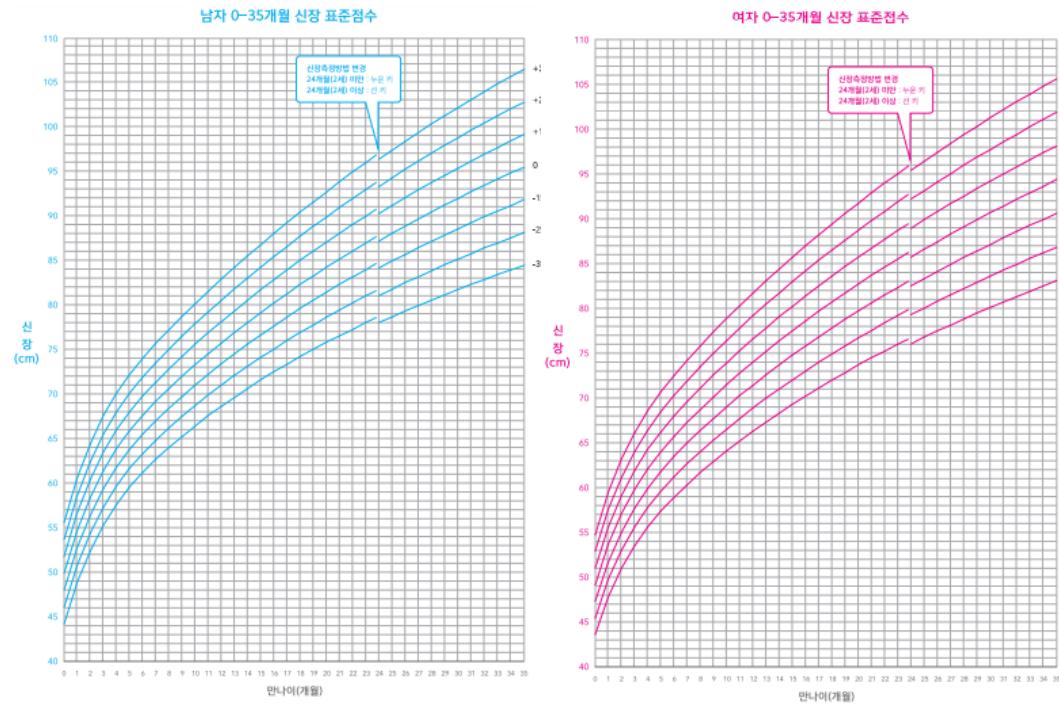
5

키 성장 예측

키 성장 예측 과정



성장 도표의 L,M,S 값을 통한 키 예측



- 1 키 성장 예측 함수
- 2 신장 예측 결과 및 성장 도표 비교
- 3 신장 곡선
- 4 GUI 구현

1 키 성장 예측 함수

키 성장 예측

키 성장 예측 2017 소아청소년성장도표 활용

소아청소년의 성장 상태가 같은 성별과 연령 내에서 어떤 위치에 있는지 판단하여 비교

Cole은 한쪽으로 쓸린 형태의 분포 값들을 정규분포로 변환하는 **Box-cox 변환 기법을 응용하여 성장 도표 값을 L,M,S 세 모수의 형태로 요약하고 이를 통해 백분위수와 표준점수를 산출하는 방법**을 개발

L

Box-Cox translation Power
데이터의 대칭성을 조정하기 위한 파라미터 Lambda를 의미

M

Median (중앙값)
데이터의 중위수를 나타내는 파라미터를 의미

S

Coefficient of Variation (변동계수)
데이터의 변동성을 나타내는 파라미터 Sigma를 의미

키 성장 예측 함수 생성

각 L, M, S의 값은 성별, 연령별로 비교 대입

함수 1 Z-Score 계산 (신장이 x 일 때)

$$f(x) = \begin{cases} ((x/M)^L - 1)/LS, & (L \neq 0) \\ [\ell_n(x/M)]/S, & (L = 0) \end{cases}$$

함수 2 만 18세의 신장 예측치
(z 에 $f_{(x)}$ 의 값 대입)

$$g(z) = \begin{cases} M(1 + LS_z)^{1/L}, & (L \neq 0) \\ M \exp(S_z), & (L = 0) \end{cases}$$

$$M_{18} \times (1 + (L_{18} \times S_{18} \times Z))^{(1/L_{18})}$$

2 신장 예측 결과_18세 기준

키 성장 예측

- 1 각 성별, 신장, 예측된 골연령을 입력하여 성장 도표(2017 소아청소년 성장 도표)와 부합하는 LMS값 구하기
- 2 신장 예측 공식을 적용한 최종 신장(만 18세 기준) 계산

골 연령 기준

8세 미만

gender	신장	골연령	gender_num	prediction
F	96.3	3.559372	2	158.179172
F	108.8	4.614071	2	164.755253
F	107.8	6.200950	2	152.439960
F	116.6	7.207135	2	155.756647

8세 - 12세

F	114.4	8.117199	2	148.672415
F	133.5	10.285060	2	155.260557
F	138.0	10.982525	2	155.569801
F	137.8	11.515267	2	152.913288

12세 이상

F	152.8	12.327424	2	160.994767
F	153.7	14.397429	2	156.485319
F	156.3	15.257227	2	157.955083
F	150.7	15.455727	2	152.923085

gender	신장	골연령	gender_num	prediction
M	97.0	3.297697	1	172.835071
M	93.6	4.579678	1	157.933082
M	107.0	5.397404	1	168.637991
M	116.4	6.104227	1	174.417683

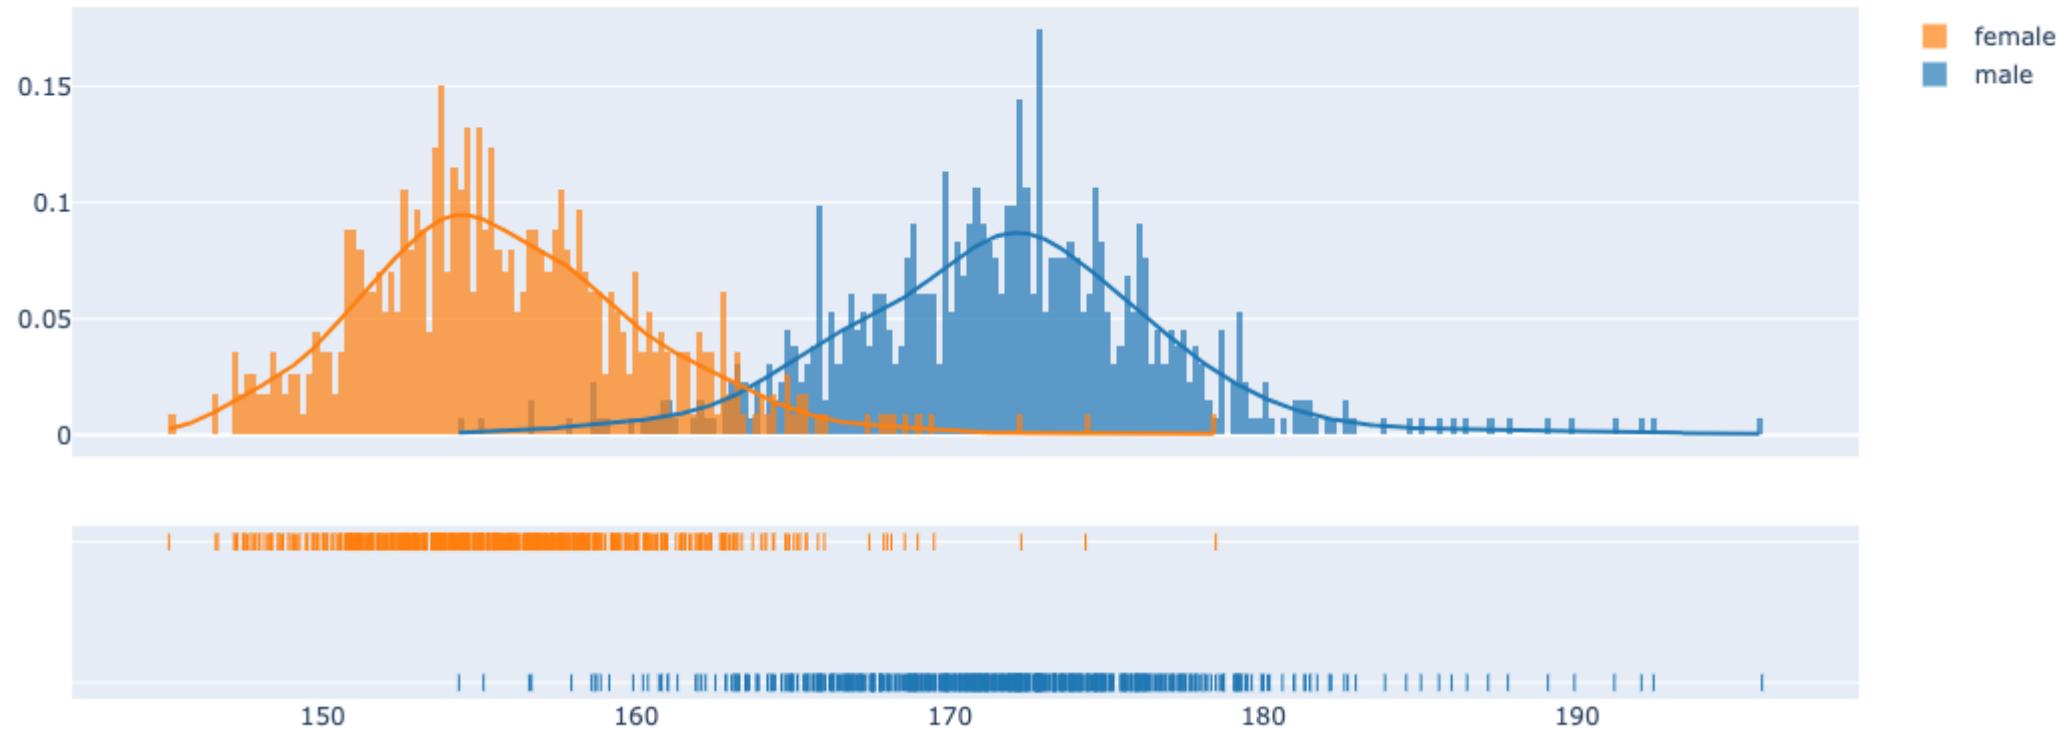
M	136.6	8.913312	1	178.727858
M	128.4	9.557222	1	166.777439
M	154.8	11.843325	1	178.148281
M	158.5	12.993910	1	174.800888

M	163.4	13.562335	1	175.549697
M	173.0	14.389323	1	180.203240
M	163.4	16.189276	1	166.716762
M	165.9	16.339016	1	168.693384

2 신장 예측 결과_그래프 시각화

키 성장 예측

성별에 따른 예측 키 히스토그램



3 신장 곡선_그래프 시각화

키 성장 예측

백분위 도표

X: 나이(만)

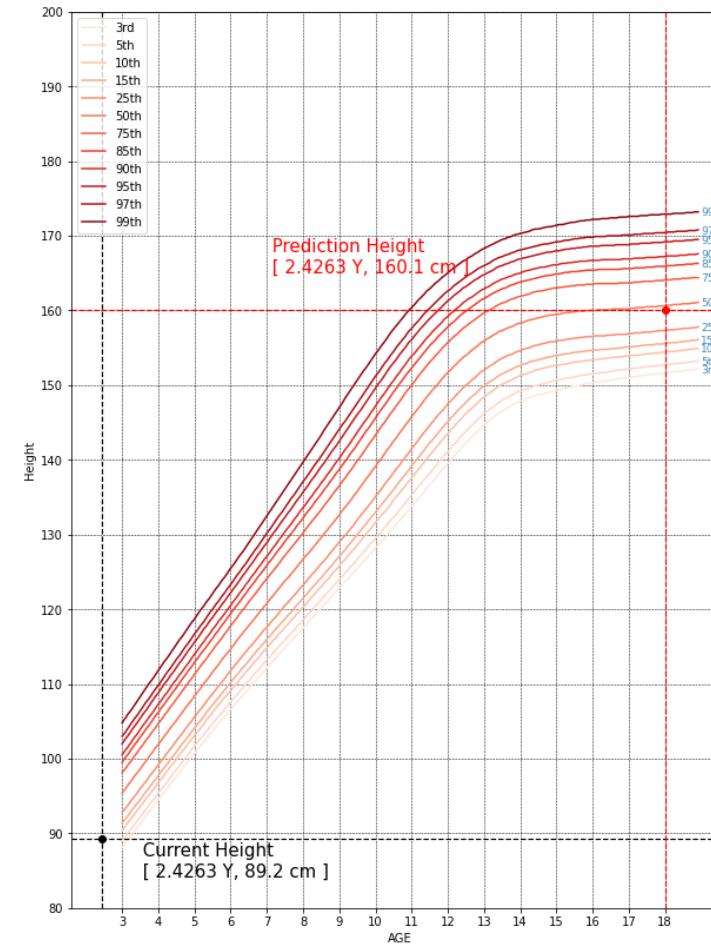
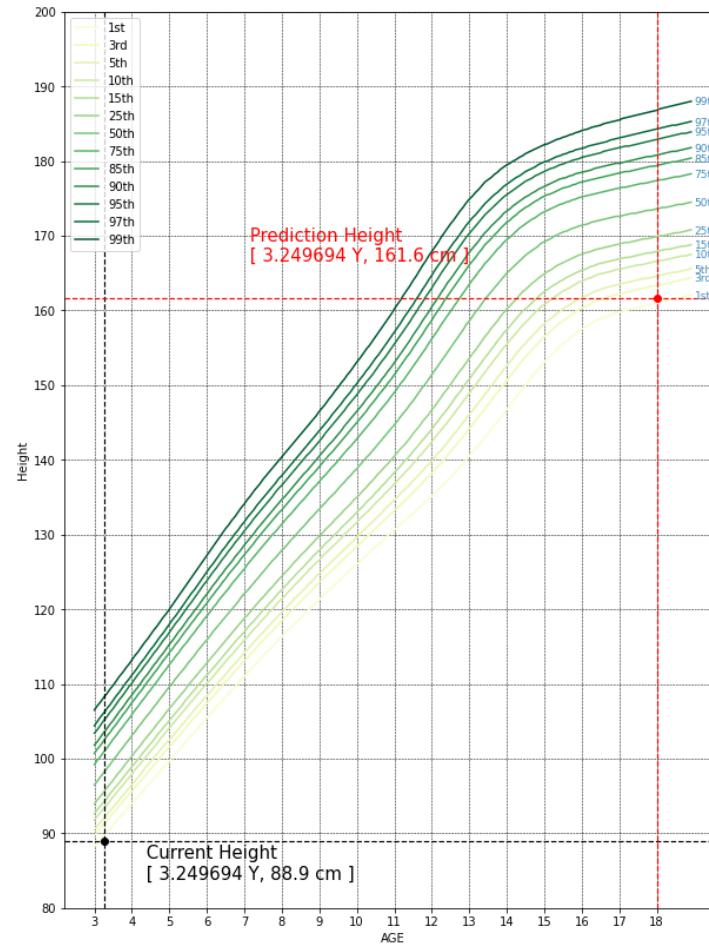
Y: 신장(cm)

male

female

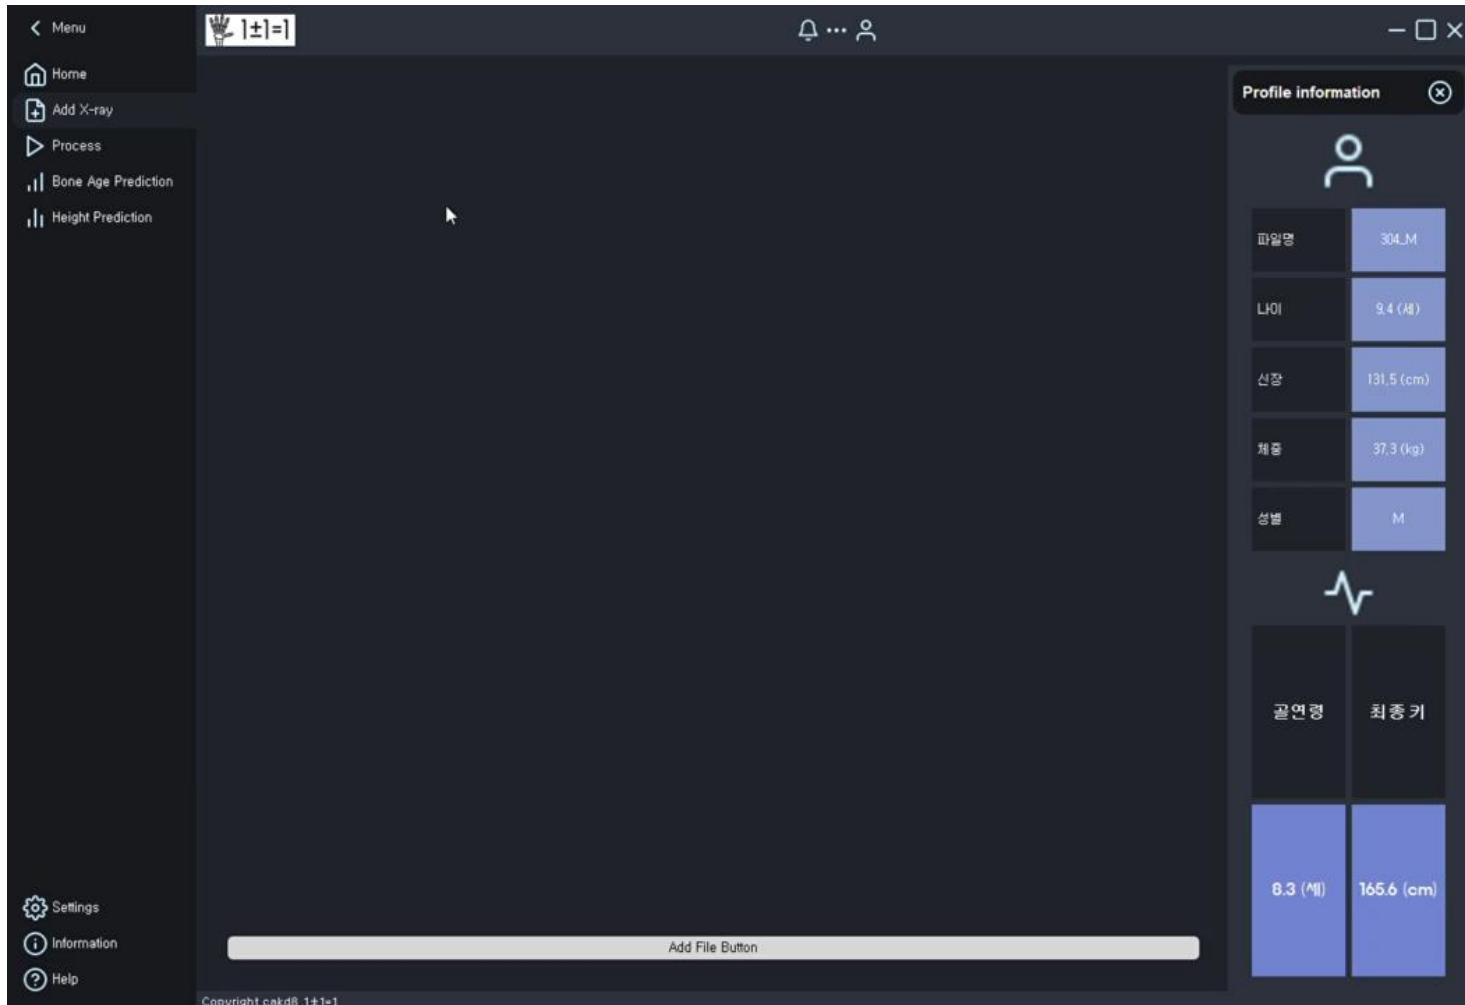
도표 보는 법:

- ① X축에서 아이의 만 나이 찾기
- ② Y축에서 아이의 현재 키 찾기
- ③ X, Y가 만나는 지점 찾기
- ④ 지점과 가장 가까운 선 찾기
- ⑤ 선을 따라 나이에 맞는 키 예측



4 GUI 구현

키 성장 예측



6

기대효과 및 한계점

기대효과 및 한계점

프로젝트 결론

기대효과

- GUI를 통해 전문의나 환자가 쉽게 이용 할 수 있도록 함
- 골 연령 및 키 연령 예측 시 딥러닝 학습 을 활용하여 시간을 절약
- 골 연령 및 키 성장 예측의 단계를 축소하여 비용적으로 유리

한계점

- 현재의 모델로는 전문의의 골연령의 측정 오차범위보다 1개월정도 더 크게 나오므로 정확도가 조금 떨어짐
- 최종 키 성장 예측 시 여러 외부적 변수 요인을 고려하지 않은 계산이며, 현재 표본의 최종 키(만 18세) 데이터가 없으므로 정확도를 판별할 수 없어 아쉬운 점이 있음

소감



최 쌤 이

YOLO를 사용하여 이미지 디텍션을 하는 것에서 그치지 않고, 그 결과를 가지고 또 다른 예측을 해낸다는 것에서 어려운 만큼 재미있었습니다. 또한 기능을 구현하는데 있어서 어려움이 있었지만, 팀원들과 멘토님의 도움으로 초반의 프로젝트 목표였던 골 연령 예측을 넘어 최종 키 예측까지 진행할 수 있었기에 다행이었고, 뿌듯했습니다.

주 지 윤

기계학습 시 일괄적인 이미지 전처리나 라벨링이 완벽하게 이루어지기에 현실적으로 힘들어서 수동적인 작업이 필수적이고 모델의 구축 시 구조에 대한 공부가 더 필요하다고 느꼈고, 그렇기 때문에 모델의 결과 개선이 좀처럼 잘 이루어 지지 않아 아쉬움이 있다.

장 유 선

수업시간에 간단하게 배운 내용들을 좀 더 분석해보고 직접 활용해볼 수 있어서 좋았다. 평소 비전 분야에 관심이 많아서 프로젝트에 재미 있게 임할 수 있었다. 모델 아키텍처를 분석하고 기존의 모델을 변형할 때 지식의 부족함도 있었지만 팀원들과 함께 공부해 나가면서 하나씩 해결해보는 좋은 경험이었다

이 현 동

짧은 4주동안 이미지 처리 주제에 모든것을 경험해볼수있는 알찬 프로젝트였다. 인상깊었던 부분은 OpenCV 기능을 통해 손 엑스레이의 뼈만 도출해내는 이미지 전처리 파트였고 결과물로 객체 탐지, 이후 골연령, 뼈 나이 전용 수식기반 최종 키 예측까지의 결과를 뽑아낸 것이 재밌었다. 전체적인 과정을 실행시켜 주는 gui도 만들어봤기에 작게나마 기능구현도 경험해보게되어 재밌었다.

박 지 훈

프로젝트를 마치며 나에게 남은 것들을 생각해 보았다.
엑스레이 이미지의 뼈를 전처리하는 법,
논문을 레퍼런스하여 라벨링 후 그에 맞는 모델을 연구하고
변형하며 여러 지표들을 비교하는 법,
그 결과 얻은 예측 골연령으로 성인 키를 예측하는 법,
그리고 팀원들과 하나가 되어 끝까지 달리는 법...
얻은 것 밖에 없는 프로젝트와 팀원을 만나 행복했다.

QnA

감사합니다.